

## 基于自适应卡尔曼滤波的视觉多目标跟踪

许华杰<sup>1,2</sup>, 郑力文<sup>1,3+</sup>

1. 广西大学 计算机与电子信息学院, 南宁 530004

2. 广西大学 广西多媒体通信与网络技术重点实验室, 南宁 530004

3. 广西水利电力职业技术学院 信息工程学院, 南宁 530023

+ 通信作者 E-mail: b869067588@163.com

**摘要:** 多目标跟踪 MOT (multi-object tracking) 旨在对视频序列中的多个目标进行识别与跟踪, 并保持各目标的 ID (identity), 对运动不规律的多目标进行跟踪是该领域的难点, 跟踪准确度难以保证且易出现目标 ID 频繁切换的问题。为提高跟踪准确度, 提出自适应卡尔曼滤波 AKF (adaptive Kalman filter), 充分利用目标检测器提供的信息对运动模型加以修正, 提高对运动不规律目标跟踪准确度; 为解决目标 ID 频繁切换的问题, 设计一种 BIoUG 贪婪算法, 通过放大匹配框并采取择优匹配的方式, 提高匹配机会并降低误匹配概率。在此基础上, 提出一种针对运动不规律目标的多目标跟踪方法。实验结果表明, 所提方法在 DanceTrack 数据集上的 MOTA、HOTA、IDF1 分别达到了 92.2%、57.7% 和 58.7%; 在 MOT17 数据集上, MOTA、HOTA、IDF1 分别达到了 80.3%、63.3% 和 77.3%。与目前主流的同类目标跟踪方法相比, 所提方法对运动不规律和规律的目标均有较好的跟踪效果, 体现出较好的综合性能, 为运动不规律多目标的跟踪提供了新的解决思路。

**关键词:** 多目标跟踪; 卡尔曼滤波; 数据关联; 轨迹匹配

**文献标志码:** A **中图分类号:** TP391 **doi:** 10.3778/j.issn.1002-8331.2405-0206

### Visual Multi-Object Tracking Based on Adaptive Kalman Filter

XU Huajie<sup>1,2</sup>, ZHENG Liwen<sup>1,3+</sup>

1. College of Computer and Electronic Information, Guangxi University, Nanning 530004, China

2. Guangxi Key Laboratory of Multimedia Communications and Network Technology, Guangxi University, Nanning 530004, China

3. College of Information Engineering, Guangxi College of Water Resources and Electric Power, Nanning 530023, China

**Abstract:** Multi-object tracking (MOT) aims to identify and track multiple targets in the video sequence, and maintain the identity of each target. Tracking multiple targets with irregular movements is a difficulty in this field. Moreover, the tracking accuracy is difficult to guarantee and the target ID is prone to frequent switching. In order to improve the tracking accuracy, the paper proposes the adaptive Kalman filter (AKF) to make full use of the information provided by the target detector to modify the motion model and improve the tracking accuracy of the moving irregular targets. In order to solve the problem of frequent switching of target ID, a greedy algorithm BIoUG is designed to increase the matching chance and reduce the mismatching probability by enlarging the matching frame and adopting the preferred matching method. On this basis, a multi-target tracking method for moving irregular targets is proposed. The experimental results show that the MOTA, HOTA and IDF1 of the proposed method on DanceTrack dataset reach 92.2%, 57.7% and 58.7%, respectively; on MOT17 dataset, MOTA, HOTA and IDF1 reach 80.3%, 63.3% and 77.3%, respectively. Compared with the current mainstream target tracking methods, the proposed method has better tracking effect on both irregular and regular targets, embodies better comprehensive performance, and provides a new way to solve the problem of irregular multi-target tracking.

**Key words:** multi-object tracking (MOT); Kalman filter; data association; trajectory matching

**基金项目:** 国家自然科学基金 (71963001); 广西科技计划项目 (2017AB15008); 崇左市科技计划项目 (FB2018001)。

**作者简介:** 许华杰 (1974—), 男, 博士, 副教授, CCF 高级会员, 研究方向为人工智能、机器视觉; 郑力文 (1998—), 男, 硕士研究生, 研究方向为人工智能、计算机视觉。

**收稿日期:** 2024-05-15 **修回日期:** 2024-07-11 **文章编号:** 1002-8331(2025)05-0200-11

目标跟踪可根据需跟踪的目标数量区分为单目标跟踪与多目标跟踪两大类。在单目标跟踪(single object tracking, SOT)中,根据给定的目标初始状态,在随后的视频帧中持续预测特定目标的状态<sup>[1-2]</sup>。相对地,多目标跟踪(multi-object tracking, MOT)旨在视频序列中识别并追踪多个目标的运动轨迹,同时保持各目标的身份(identity, ID)。近年来,由于在学术研究和实际应用中具有巨大潜力, MOT 领域吸引了越来越多的关注,已成为计算机视觉研究的热点方向。当前,多目标跟踪的方法可大致分为基于粒子滤波<sup>[3]</sup>和基于深度学习两大类。深度学习模型以其卓越的泛化能力和高效的特征提取能力而著称,得益于深度学习中目标检测领域的发展,研究者倾向于采用基于检测的跟踪(tracking by detection, TBD)范式来完成此类任务,通过深度学习目标检测模型获取目标位置信息,然后利用运动模型预测目标轨迹,最后将预测结果与目标位置相互匹配以完成目标追踪。王雒等人<sup>[4]</sup>提出了一种多目标跟踪算法用于红外多目标跟踪,该算法通过深度学习目标检测模型充分提取目标特征信息,再采用卡尔曼滤波运动模型与匈牙利匹配算法相结合的方式完成目标跟踪。曹玉东等人<sup>[5]</sup>基于DeepSort多目标跟踪框架,并融合了深度学习目标检测模型Mask R-CNN来提取目标外观特征,以提升对行人多目标跟踪准确度。Du等人<sup>[6]</sup>提出了一种StrongSort的多目标跟踪方法,利用深度学习模型来提取目标特征并引入了惯性项EMA来平滑特征更新,提升了跟踪的稳定性。当前,基于TBD范式的主流多目标跟踪方法在目标运动规律较简单的MOT任务中取得了较好的效果。

然而在对运动不规律的目标跟踪时,例如针对多目标跟踪数据集DanceTrack<sup>[7]</sup>中运动不规律的舞者进行跟踪时,当前主流基于TBD范式的多目标跟踪方法进行跟踪的效果不够理想。其主要原因有两点:(1)运动轨迹预测较差。TBD范式中常用卡尔曼滤波作为运动模型进行运动轨迹预测,而卡尔曼滤波是假设目标运动规律的情况下进行的运动轨迹预测,因此当跟踪目标突然加速或转弯等不规律运动的情况下,该算法对运动轨迹的预测可能产生偏差,导致其难以与检测目标结果相匹配,进而降低跟踪准确性<sup>[8]</sup>。(2)匹配空间过小。由于TBD范式在目标运动不规律的情况下,可能用于检测和预测结果进行匹配的空间过小,使得两者可能出现无重叠部分的情况,导致无法匹配,因此造成跟踪目标丢失<sup>[9]</sup>。

本文针对上述现有研究的不足提出解决方案:为了提高运动轨迹预测的准确性,提出自适应卡尔曼滤波(adaptive Kalman filter, AKF),利用深度学习目标模型提供的信息同时对预测阶段的过程噪声和更新阶段的观测噪声协方差矩阵进行自适应更新,以加强对运

动不规律目标的运动轨迹预测能力;为了解决匹配空间过小问题,提出一种基于BIoU的贪婪算法(buff IoU greedy, BIoUG),该算法围绕深度学习目标检测模型得到的置信度来进行设计,在第二次匹配时扩大匹配空间并提高匹配正确率。在此基础上,结合所提出的AKF及BIoUG并基于TBD范式提出一种二次匹配的多目标跟踪方法(BIoUG-adaptive Kalman filter, B-AKF)。实验表明,与目前主流的同类目标跟踪算法相比,所提方法对运动不规律的目标有较好的跟踪效果,对运动较为规律的目标进行跟踪也有较好的表现。有效弥补当前基于TBD范式的主流多目标跟踪方法对运动不规律的目标进行跟踪时跟踪准确度较低的问题,为复杂跟踪任务提供有效的解决方案。

## 1 相关工作

### 1.1 多目标跟踪范式

近年来,一些研究开始关注对运动不规律多目标的跟踪任务:Cao等人<sup>[8]</sup>为解决目标运动不规律导致卡尔曼滤波(Kalman filter, KF)预测不可靠问题,提出三个以观测为中心的算法来平缓KF参数,以增强非线性运动下进行鲁棒跟踪能力,但更严重地直接依赖检测来减轻对象遮挡或消失的影响;Yang等人<sup>[9]</sup>在二次级联匹配中,通过设置不同比例扩展跟踪框和检测框大小,以增大匹配概率,缓解不规则运动导致的无法匹配问题从而提高跟踪性能,但该方法也同时增加误匹配的可能,降低了算法对噪声的抗干扰能力;Zeng等人<sup>[10]</sup>提出了一种仅通过目标间本质特征进行关联的端到端多目标跟踪方法,但是存在计算速度慢、跟踪性能较差的缺点;Du等人<sup>[11]</sup>使用了一种无外观模型提升轨迹匹配精确性,还使用NSA卡尔曼滤波增强运动模型的预测,但其对运动模型的优化有限。上述MOT方法有检测联合跟踪(jointly learns the detector and embedding, JDE)范式和TBD范式两大类,与JDE范式方法相比,TBD范式方法的成本更低、速度更快,已广泛应用于MOT任务。当前基于TBD范式对运动不规律目标跟踪的MOT方法主要围绕优化运动模型,以及提升轨迹匹配算法精确度来展开研究。

### 1.2 运动模型

运动模型是TBD范式多目标跟踪方法中的重要组件之一,它通过对目标在视频中的运动轨迹进行建模来预测目标的位置。卡尔曼滤波KF是常用的运动模型之一,它能够通过系统输入的观测数据,基于线性系统状态方程对系统状态进行最优估计,能够较好解决针对线性运动的跟踪问题。然而,KF主要考虑线性运动的情况,在非线性运动的状态估计中效果不佳。为了弥补这一不足,Extended KF等基于卡尔曼滤波的变体随后被提出,通过将非线性系统在其参考点处做泰勒级数展开来

处理非线性运动的估计问题,然而该方法仍依赖于近似KF假设的高斯先验,缺少针对MOT任务特点的专门处理。当前,大多数MOT方法采用的运动模型仍然是原始的卡尔曼滤波或利用MOT任务中帧间轨迹相关信息优化的卡尔曼滤波<sup>[8,11]</sup>,未充分利用目标检测器提供的结果信息。本文通过提出自适应卡尔曼滤波AKF以充分利用该信息对运动模型进行调整,用于解决对运动不规律多目标进行跟踪的问题。

### 1.3 数据关联

在多目标跟踪方法中,数据关联通过计算运动模型等预测结果与检测器检测结果的相似度,运用匹配算法为对象分配身份。相似度计算可以由位置信息、外观信息得出,例如:Zhang等人<sup>[12]</sup>提出ByteTrack通过计算检测框与预测框的IoU(intersection over union)作为位置相似度,但在跟踪目标不规律运动的情况下,可能存在IoU过低进而使得跟踪目标丢失的问题;Wojke等人<sup>[13]</sup>提出的方法通过Re-ID模型提取目标外观特征计算相似度,但在目标外观相似的情况下效果不佳。匹配算法一般使用匈牙利算法或贪婪算法,如Bewley等人<sup>[14]</sup>提出方法以检测框与预测框IoU作为位置相似度,通过匈牙利算法将检测框与轨迹进行匹配,但其跟踪的鲁棒性不强;Bochinski等人<sup>[15]</sup>提出的方法不进行运动预测,而是基于IoU相似度直接用贪婪算法为相邻两帧的所有检测框进行匹配,因此帧间相关信息缺乏关联,导致出现较多ID交换的现象。

数据关联根据需要可以采用一次匹配或两次匹配的策略,相较于一次匹配,两次匹配可以增加匹配轨迹数量,从而提升整体的跟踪性能。两次匹配的算法选择方面,由于匈牙利算法考虑全局最优解,贪婪算法考虑局部最优解,因此在两次匹配中都使用其中一种方法会有一定的局限性。上述这些数据关联方法对运动不规律目标跟踪场景缺乏足够优化,导致其跟踪的鲁棒性不

强,而且在运动规律目标跟踪方面表现较好的二次匹配策略未能较好迁移到运动不规律目标的跟踪上。综合上述分析,本文提出的B-AKF采用二次匹配策略,并在第二次匹配时使用所提出的BIOUG贪婪算法以提高匹配机会并降低误匹配概率。

## 2 基于自适应卡尔曼滤波的视觉多目标跟踪方法

### 2.1 方法架构

针对卡尔曼滤波不适合用于复杂情况下运动轨迹的预测以及基于TBD范式的二次匹配策略中仅使用匈牙利算法进行匹配所存在的局限性,本文采用多目标跟踪方法ByteTrack<sup>[12]</sup>类似的框架,基于自适应卡尔曼滤波AKF和BIOUG贪婪算法提出一种采用二次匹配策略的多目标跟踪方法B-AKF。B-AKF中采用的二次匹配策略分两个阶段进行:首先,在第一次匹配阶段使用匈牙利算法,优先将高分检测框与未匹配的轨迹进行关联,确保高可靠性目标优先得到匹配,以提升匹配的准确性,从而增强跟踪的精确度;然后,在第二次匹配阶段使用所提出的BIOUG算法,将低分检测框与在第一次匹配中未能成功匹配的轨迹进行关联,有助于降低漏匹配的可能性,从而进一步提高跟踪的准确性。传统的一次匹配方法通常采用两种策略都会引发一定的问题:一种是将高分检测框和低分检测框混合在一起进行一次性匹配,可能会导致低分检测框错误地与轨迹匹配,从而取代了本应与高分检测框匹配的轨迹,造成匹配错误;另一种是仅对高分检测框进行匹配而忽略低分检测框,这将会造成不可忽视的漏检问题,还可能导致轨迹的碎片化,这些都会对跟踪效果产生不利影响。而B-AKF通过二次匹配给予高分检测框和低分检测框充分的匹配机会,可以有效提高跟踪准确度,并减少漏跟踪等现象,提升方法整体的跟踪性能。B-AKF的架构如图1所示,分为检测与跟踪两个部分。




图1 B-AKF方法架构图

Fig.1 B-AKF structure diagram



检测部分:首先使用目标检测器YOLOx<sup>[16]</sup>对当前帧(设为第 $k$ 帧)输入图像进行目标检测,得到目标的检测框及目标类别的置信度分数,而置信度分数代表了目标检测器对于检测框中包含目标的置信程度,这个分数是基于目标检测器对检测框中内容的分析和判断得出的。高置信度分数通常意味着高度确信检测框中包含目标,且目标的类别标注是正确的;而低置信度分数则表明检测框中的内容存在不确定性,可能是由于目标遮挡、光照变化、快速运动等因素导致,因此根据置信度分数进行划分便于后续对不同级别的检测框采取不同的处理方式,以提升轨迹匹配的准确性;然后根据置信度分数阈值 $\tau$ (参考文献[12]做法, $\tau$ 取0.6)将所有检测框分为高分检测框和低分检测框两部分。检测部分执行结束后执行跟踪部分。

跟踪部分又分为轨迹匹配与轨迹管理两个部分。(1)轨迹匹配:首先由所提出的AKF预测出每条待匹配轨迹(第 $k-1$ 帧中所有的跟踪框)在当前帧的位置,并与高分检测框进行IoU计算后使用匈牙利算法进行第一次匹配得到已匹配轨迹和未匹配轨迹,前者添加到已匹配轨迹集合 $T_{\text{match}}$ 中,后者添加到未匹配轨迹集合 $T_{\text{unmatch}}$ 中;然后将 $T_{\text{unmatch}}$ 中每条未匹配轨迹分别与低分检测框通过所提出的BIOUG算法进行第二次匹配以实现对剩余目标轨迹的匹配,并将匹配后的轨迹添加到已匹配轨迹集合 $T_{\text{match}}$ 中,而仍未匹配的轨迹则标记为“丢失轨迹”并添加到轨迹丢失集合 $T_{\text{lost}}$ 中。(2)轨迹管理:首先,在第二次匹配结束后对AKF中的变量进行更新;然后,对于在第一次匹配后从未匹配的高分检测框 $D_{\text{unmatch}}$ ,若高分检测框 $D_{\text{unmatch}}$ 存在于两帧以上,则将高分检测框 $D_{\text{unmatch}}$ 选定的目标视为新目标并初始化该目标轨迹;最后,若丢失轨迹未能在指定帧数(参考相关研究的做法<sup>[4,12]</sup>,此处取30帧)内匹配成功,则将该丢失轨迹从轨迹丢失集合 $T_{\text{lost}}$ 中移除(判断该轨迹所对应目标已离开跟踪区域),以节省计算资源。

## 2.2 自适应卡尔曼滤波AKF

卡尔曼滤波KF是MOT中常用的运动模型,由预测阶段和更新阶段组成。在预测阶段,目标运动过程中的预测值与真实值之间的误差主要由过程的噪声协方差矩阵 $Q$ 来衡量;在更新阶段,观测值(这里指目标检测器的检测结果)的误差由观测的噪声协方差矩阵 $R$ 来衡量。KF基于目标运动为线性的假设,设定 $Q$ 、 $R$ 是一组常数矩阵。文献[6,11]使用的自适应卡尔曼滤波利用目标检测器提供的置信度分数为观测的噪声协方差矩阵 $R$ 进行更新,以增强对非线性目标的跟踪能力,但对目标检测器提供的信息未能充分利用且忽略了对运动过程的噪声协方差矩阵 $Q$ 进行更新。文献[8]认为鲁棒MOT方法应该更重视观测值,并基于此提出三个以观测为中心的算法来平缓KF参数,以增强非线性运动

下鲁棒跟踪的能力,但其过于依赖观测值且对于目标跟踪器提供的信息利用不足。总的来说,KF、其他KF变体等运动模型仅利用目标检测结果中的坐标信息,对其余的信息如置信度分数、隐含的相对位置关系未能充分利用,而此类信息对于辅助运动模型更加准确地判断目标运动状态以提升非线性运动目标的跟踪效果有较大帮助。本文提出的自适应卡尔曼滤波AKF可以充分耦合目标检测的结果,其主要特点有:(1)利用目标检测器提供的置信度分数对观测噪声协方差矩阵进行自适应调整;(2)用目标检测器提供隐含的相对位置关系对运动过程噪声矩阵进行更新,即用目标预测框与检测框之间的IoU来衡量运动噪声导致预测误差的程度,并以该IoU作为权重对运动过程的噪声协方差矩阵进行自适应更新。AKF流程分为状态预测和状态更新两个过程,其中,状态预测的过程如下所示。

运动状态预测:

$$\hat{x}_{k|k-1} = Fx_{k-1} \quad (1)$$

运动过程协方差矩阵预测:

$$P_{k|k-1} = FP_{k-1}F^T + Q_{k-1} \quad (2)$$

式(1)中, $x_{k-1}$ 为第 $k-1$ 帧的运动状态, $F$ 为状态转移矩阵; $\hat{x}_{k|k-1}$ 为运动状态估计值,即通过 $k-1$ 帧的运动状态 $x_{k-1}$ 预测 $k$ 时刻的运动状态。式(2)中, $P_{k-1}$ 为第 $k-1$ 帧的过程协方差矩阵, $P_{k|k-1}$ 为过程协方差矩阵估计值, $Q_{k-1}$ 为第 $k-1$ 帧过程的噪声协方差矩阵。

状态预测之后,为了获取状态更新过程所需参数,通过运动状态估计值 $\hat{x}_{k|k-1}$ 中包含的位置信息(预测框)与观测值 $Z_k$ (高分检测框)进行交并比计算得到IoU,并根据IoU再使用匈牙利算法进行第一次匹配,即用估计值 $\hat{x}_{k|k-1}$ 与对应的观测值 $Z_k$ (高分检测框)进行匹配,并获取观测值的置信度分数 $c_k$ ( $0 \leq c_k \leq 1$ )。状态更新的过程如下所示。

采用NSA卡尔曼滤波<sup>[11]</sup>对观测噪声协方差矩阵 $R_0$ 进行更新:

$$\tilde{R}_k = (1 - c_k)R_0 \quad (3)$$

其中, $c_k$ 为第 $k$ 帧中对应目标的置信度分数, $R_0$ 为初始观测噪声协方差矩阵, $\tilde{R}_k$ 为第 $k$ 帧中自适应观测噪声协方差矩阵。式(3)通过在第一次匹配完成后根据观测值的置信度 $c_k$ 对初始观测噪声协方差矩阵 $R_0$ 进行动态改变得到 $\tilde{R}_k$ 。

计算卡尔曼滤波增益:

$$K_k = P_{k|k-1}H^TS_k^{-1}(HP_{k|k-1}H^T + \tilde{R}_k)^{-1} \quad (4)$$

更新运动状态:

$$x_k = \hat{x}_{k|k-1} + K_k(Z_k - H\hat{x}_{k|k-1}) \quad (5)$$

更新运动过程协方差矩阵:

$$P_k = (1 - K_kH)P_{k|k-1} \quad (6)$$

式(4)~式(6)中, $H$ 为观测矩阵, $K_k$ 、 $x_k$ 、 $P_k$ 、 $Z_k$ 分别

为第  $k$  帧中的卡尔曼滤波增益、运动状态、运动过程协方差矩阵、观测值。根据观测值  $Z_k$  及动态观测噪声协方差矩阵  $\tilde{R}_k$  对预测阶段得到的运动状态  $\hat{x}_{k|k-1}$  及运动过程协方差矩阵  $P_{k|k-1}$  进行更新,得到最终运动状态  $x_k$  及运动过程协方差矩阵  $P_k$ 。

最后根据所提出的公式对运动过程的噪声协方差矩阵进行自适应调整,计算过程如下所示。

计算运动状态的误差:

$$\hat{w}_k = x_k - \hat{x}_{k|k-1} \quad (7)$$

更新误差的协方差矩阵:

$$Q_k = \hat{w}_k \hat{w}_k^T \quad (8)$$

自适应更新运动过程噪声的协方差矩阵:

$$Q_k = IoU * Q_{k-1} + (1 - IoU) * \hat{Q}_k \quad (9)$$

先采用式(7)计算跟踪框的最终运动状态  $x_k$  与运动状态预测值  $\hat{x}_{k|k-1}$  的误差,然后通过式(8)得到误差的协方差矩阵  $\hat{Q}_k$ ,最后由式(9)根据 IoU 为误差协方差矩阵  $\hat{Q}_k$  与第  $k-1$  帧中的过程噪声协方差矩阵  $Q_{k-1}$  分配不同的权重,以自适应地更新第  $k$  帧的过程噪声协方差矩阵  $Q_k$ 。

本文所提出的 AKF 主要是在 KF 的基础上,增加了对观测噪声协方差矩阵、运动过程噪声协方差矩阵的自适应更新,这么做的动机主要体现在以下两个方面:

(1)对于观测噪声协方差矩阵,由于观测值是由目标检测器提供而目标检测器对目标的检测是有置信度分数的,这表明目标检测结果不是完全可靠的,其可靠程度反映在检测置信度分数  $c_k (0 \leq c_k \leq 1)$  上,而用恒定的观测噪声协方差矩阵难以反映观测值的可靠程度。因此,利用置信度分数来调整观测噪声协方差矩阵是提高观测结果精确性和有效性的可行方式。借鉴 Sage-huge 算法中使用加权系数更新预测和观测的均值及协方差矩阵的方法<sup>[17]</sup>,并结合实际置信度分数与噪声尺度成反比的关系,故将观测噪声协方差矩阵的权重系数设置为  $1 - c_k$ 。

(2)对于运动过程噪声协方差矩阵,协方差匹配是进行自适应估计的方法之一,它根据实际测量值与预测值之间的差值对 KF 的协方差矩阵进行调整<sup>[18]</sup>。据此,并借鉴文献[18-19]的做法,用目标的最终运动状态与对运动状态预测的差值来计算运动状态误差  $\hat{w}_k$ 。参考文献[19]的做法,用运动状态误差  $\hat{w}_k$  与自身的转置矩阵相乘构造误差协方差矩阵  $\hat{Q}_k$ 。此外,文献[17-18]在对噪声协方差矩阵进行更新时都采用了加权系数的形式,并结合前一状态的误差协方差矩阵和根据当前状态构造的误差协方差矩阵来更新误差协方差矩阵,借鉴这些文献的做法并结合多目标跟踪的实际情况,使用 IoU 值作为权重,对第  $k$  帧的运动过程噪声协方差矩阵  $Q_{k-1}$  和误差协方差矩阵  $\hat{Q}_k$  进行加权并求和得到第  $k$  帧的运动

过程噪声协方差矩阵  $Q_k$ 。使用 IoU 值作为权重的原因是 IoU 反应了预测结果(预测框)和检测结果(检测框)的重合程度,一定程度上反映了预测结果的误差程度。具体而言,当 IoU 接近 1 时,预测框与检测框几乎完全重叠,表明预测误差较小,此时  $Q_k$  接近于  $Q_{k-1}$ ;当 IoU 接近 0 时,预测框与检测框几乎没有重叠,表明预测误差较大,此时  $Q_k$  主要依赖于误差协方差矩阵  $\hat{Q}_k$  进行更新。引入自适应更新机制的目的是生成一个较为准确且有效,可与实际运动场景较好匹配的过程噪声协方差矩阵。

综上所述,AKF 相较于 KF 及其改进型版本,充分利用了目标检测器的检测结果,用目标检测器提供的信息对运动模型加以修正,有助于提高对运动不规律目标的跟踪准确度,以适应复杂多变的运动场景。

### 2.3 BIoUG 贪婪算法

为解决数据关联过程中匹配空间过小的问题,文献[9]提出一种 BIoU(buff IoU)方法,并将其用于二次级联匹配中。该方法以增强比例  $b$  等参数扩大运动轨迹预测框和检测框后进行交并比计算,有利于在相邻帧之间预测框和检测框没有重叠时加大匹配的可能。但是当多个预测框与检测框之间存在大量相互重叠区域时,这种做法可能会加大误匹配发生的概率,两次匹配都采用 BIoU 的情况下,误匹配的可能性会进一步增加。

此外,文献[6]额外构造了一个深度学习模型来处理数据关联,但这需要额外的深度学习模型训练;文献[11]提出了一种改进的 ResNet50-TP 链接算法,用于提取轨迹的 3D 特征并进行时间与空间距离的关联,但该方法需要对 6 个超参数(包括 3 个阈值和 3 个权重因子)进行微调,这可能导致需要进行较多的调参实验,并降低了算法的鲁棒性。文献[4, 12]采用了二次匹配策略,并在两次轨迹匹配中都使用了考虑全局最优的匈牙利算法,但参与第二次匹配的是第一次匹配后剩余的未匹配轨迹和低分检测框,这导致第二次匹配的成功率较低或误匹配率较高,而使用匈牙利算法可能会进一步放大匹配结果的误差。文献[14]提出了一个基于 IoU 的匹配算法,但在 IoU 为 0 的情况下无法成功匹配。综合上述分析,针对数据关联过程中匹配空间过小导致匹配准确率较低以及匈牙利算法时间复杂度较高的问题提出 BIoUG 贪婪算法,该算法具有以下特点:(1)相比于大多数主流匹配算法,BIoUG 算法能在匹配过程中通过扩大参与匹配的检测框与预测框尺寸,减少 IoU 为 0 的情况,从而提高匹配概率;此外,该算法所含超参数只有两个,不需要模型训练,因此成本较低。(2)在第二次轨迹匹配场景中,相比于匈牙利算法,BIoUG 算法能让多个低分检测框中置信度较高的先匹配,这更符合实际情况,有利于降低误匹配概率,并且可获得更好的性能以及更低的时间复杂度。BIoUG 贪婪算法的流



程如算法1所示。

在算法1中,首先对低分检测框集合中的检测框按置信度大小降序排列(第1行);然后遍历未匹配轨迹集合  $T_{\text{unmatch}}$ ,并初始化变量  $biou_{\text{max}}$  用于保存当前轨迹  $t(t \in T_{\text{unmatch}})$  与低分检测框  $d(d \in D_{\text{low}})$  通过增强比例为  $b$  的BIoU计算后的最大值(第2~3行);然后对低分检测框集合中的检测框分别做BIoU计算,保留其中最大的  $biou$  赋给  $biou_{\text{max}}$  (第4~9行);若  $biou_{\text{max}}$  大于给定阈值  $\theta$ ,则轨迹匹配成功,将轨迹  $t$  从未匹配轨迹集合  $T_{\text{unmatch}}$  移除,并添加到已匹配轨迹集合  $T_{\text{match}}$  (第10~12行);匹配完成后对于未匹配的轨迹  $t(t \in T_{\text{unmatch}})$ ,若轨迹状态  $t.state$  不是“丢失轨迹”状态  $track.lost$ ,则将该轨迹状态设置为“丢失轨迹”状态  $track.lost$ ,并添加到轨迹丢失集合  $T_{\text{lost}}$  (第14~18行);最后返回已匹配成功的轨迹集合  $T_{\text{match}}$  和轨迹丢失集合  $T_{\text{lost}}$  (第19行)。

算法的核心——BIoU的计算过程如图2所示,流程如下:首先分别扩大轨迹  $t$  的预测框及低分检测框的大小(第5~6行),然后在此基础上进行IoU计算,其计算结果记为  $biou$  (第7行),保留其中最大的  $biou$  赋给  $biou_{\text{max}}$  (第8行)。该算法核心思想是:由于第二次匹配的成功率较低或误匹配率较高,因此通过将检测框按置信度分数大小降序排序并从低分检测框中选取置信度较高的部分,优先与第一次匹配中未匹配轨迹匹配,而不是匈牙利算法所考虑的尽量保证未匹配轨迹都能匹配,以降低误匹配的概率;此外,在匹配时通过扩大参与匹配的检测框与预测框的大小,增加数据关联过程中匹配空间,以提高匹配成功的概率。

#### 算法1 BIoUG贪婪算法

输入:低分检测框集合  $D_{\text{low}}$ ,增强比例  $b$ ,匹配阈值  $\theta$ ,




图2 BIoU的计算过程

Fig.2 Process of calculating BIoU

未匹配轨迹集合  $T_{\text{unmatch}}$ ,已匹配轨迹集合  $T_{\text{match}}$ ,轨迹丢失集合  $T_{\text{lost}}$ 。

输出:已匹配轨迹集合  $T_{\text{match}}$ ,丢失轨迹集合  $T_{\text{lost}}$ 。

```

1.  $D_{\text{low}} \leftarrow \text{Sort}(D_{\text{low}})$  //根据置信度从高到低排序低分检测框
2. for  $t$  in  $T_{\text{unmatch}}$  do:
3.    $biou_{\text{max}} = 0$ 
4.   for  $d$  in  $D_{\text{low}}$  do:
5.      $tbox = \text{Expand}(t, b)$  //根据参数  $b$  扩大轨迹  $t$  的预测框
6.      $dbox = \text{Expand}(d, b)$  //根据参数  $b$  扩大低分检测框  $d$ 
7.      $biou = \text{IoU}(tbox, dbox)$  //计算交并比
8.      $biou_{\text{max}} = \text{MAX}(biou_{\text{max}}, biou)$  //求最大的交并比
9.   end for
10.  if  $biou_{\text{max}} \geq \theta$ :
11.    remove  $t$  from  $T_{\text{unmatch}}$ 
12.    add  $t$  to  $T_{\text{match}}$ 
13. end for
14. for  $t$  in  $T_{\text{unmatch}}$  do:
15.   if  $t.state \neq track.lost$ :
16.     $t.state = track.lost$ 
17.    add  $t$  to  $T_{\text{lost}}$ 
18. end for
19. return  $T_{\text{match}}, T_{\text{lost}}$ 
    
```

### 3 实验及其结果分析

#### 3.1 实验设置及环境

在两个主流多目标跟踪的公共数据集 DanceTrack<sup>[7]</sup>、MOT17<sup>[20]</sup>上进行实验,以评估所提出方法的多目标跟踪性能。其中,DanceTrack数据集包含训练集、验证集和测试集,共100个舞者跳舞的视频序列,共包含105 855个视频帧,待跟踪目标(舞者)具有相似外观且运动不规律的特征。MOT17数据集包括训练集和测试集,主要是室内和室外的公共场所中行人的7个不同视频序列,包含15 948个训练帧和17 757个不同输入分辨率的测试帧,待跟踪目标(行人)的外观区分大,且运动较为规律。

模型训练设置及参数:所提出的B-AKF采用的目标检测器为YOLOx<sup>[16]</sup>,它以YOLOx-x为主干,COCO数据集预训练模型为初始化权值。与文献[12]相同,在MOT17的训练集上进行训练,目标检测模型输入图像大小为1 440×800,在多尺度训练时,最短边长范围为576~1 024。根据相关文献经验,采用的数据增强方法包括Mosaic和Mixup;优化器是SGD,权重衰减为 $5 \times 10^{-4}$ ,动量为0.9;初始学习率为 $10^{-3}$ ,使用1 epoch训练预热及余弦退火策略。与文献[7]相同,在DanceTrack的验证,测试集上进行实验时,目标检测模型是MOT17训

练集上得到的模型再在DanceTrack的训练集上进行训练得到。

实验环境:实验在Python3.8环境下基于PyTorch深度学习框架来进行,操作系统为Window10,CPU为AMD Ryzen 5 5600X,内存为16 GB,GPU为GeForce RTX 2080Ti。

### 3.2 评估指标

本文参考文献[6,8,12]的做法,采用领域内常用的MOTA、IDF1、HOTA以及FPS指标用于评估方法的多目标跟踪性能。MOTA由误检测目标数FP、漏检目标数FN和ID切换总数IDs计算,反映了多目标跟踪准确度,计算方式如式(10)所示,其中GT为真实目标数。

$$MOTA = 1 - \frac{\sum(FN + FP + IDs)}{\sum GT} \quad (10)$$

IDF1是跟踪ID的F1得分,主要用于评估身份保持能力,更侧重数据关联性能,计算方法如式(11)所示。其中,IDTP、IDFP和IDFN分别表示正确匹配的ID数量、不正确匹配的ID数量和未匹配ID数量。

$$IDF1 = \frac{2 \times IDTP}{2 \times IDTP + IDFP + IDFN} \quad (11)$$

HOTA是近年来出现的一个评估指标,通过计算各定位误差阈值下的目标检测精度和关联精度的几何平均值,对模型检测、关联和定位的效果进行全面评价。FPS指每秒能处理的图像帧数,用于反映方法的时效性。

### 3.3 BIoUG算法的超参数实验

在所提出的B-AKF方法中,BIoUG算法的增强比例 $b$ 及匹配阈值 $\theta$ ( $0 \leq \theta \leq 1$ )是关键超参数,为此通过在DanceTrack数据集上的实验探究这两个超参数对跟踪性能的影响,并为后续实验确定超参数取值。实验过程中,首先形成 $b$ 和 $\theta$ 的组合 $[b, \theta]$ ,其中两个超参数的范围都从0.1到0.9,步长都为0.1,并通过实验评估它们对方法跟踪性能的影响。实验结果如图3所示,从中可以

发现:当 $b$ 与 $\theta$ 过小或过大时,所对应的MOTA、IDF1和HOTA三个指标得分较低。导致该现象的可能原因是:当 $\theta$ 过小且 $b$ 过大时,多个检测框与预测框会过量放大导致彼此重叠,进而加大出现误匹配的概率;反之当 $\theta$ 过小且 $b$ 过小时,多个检测框与预测框可能无重叠区域,导致出现匹配失败现象;而当 $\theta$ 过大, $b$ 过大或过小时,由于阈值 $\theta$ 过大导致匹配的门槛较高,匹配成功的概率下降。当 $b$ 与 $\theta$ 都接近0.5时所对应的三个指标得分都较高,特别是当 $b$ 和 $\theta$ 的取值组合为[0.4,0.6]时得到最优MOTA、IDF1和HOTA,分别是90.2%、55.6%及54.82%,因此在后续的实验中都采用此超参数取值组合。

### 3.4 运动模型相关性实验

为了测试所提出运动模型AKF的性能,在DanceTrack验证集上使用相同的目标检测器YOLOx,将AKF与不同的运动模型进行比较。实验结果如表1所示,其中指标后的“↑”表示该指标的数值越大越好,指标的单位都为“%”,最佳结果以粗体显示。

表1 不同运动模型在DanceTrack验证集上的对比

| Motion               | DanceTrack validation set |             | 单位:%        |
|----------------------|---------------------------|-------------|-------------|
|                      | MOTA ↑                    | HOTA ↑      | IDF1 ↑      |
| KF                   | 88.1                      | 47.0        | 51.1        |
| LSTM <sup>[21]</sup> | 89.2                      | 51.6        | 50.8        |
| ORU <sup>[7]</sup>   | 87.3                      | 52.1        | 51.6        |
| AKF(Ours)            | <b>90.2</b>               | <b>54.2</b> | <b>54.3</b> |

从表1可知,在DanceTrack验证集上,提出的运动模型AKF所对应的MOTA、HOTA、IDF1三个指标均优于KF、ORU(KF变体的运动模型)及LSTM(非KF变体的运动模型)。AKF性能上的优势主要原因是由于其在KF运动模型的基础上,充分利用目标检测器的检测结果来进行自适应更新,有助于其在不规律运动场景下获




图3 B-AKF方法的超参数 $b$ 及 $\theta$ 实验结果

Fig.3 Experimental results for hyperparameter  $b$  and  $\theta$  of B-AKF

得较好的表现。

3.5 性能对比实验

将所提出的多目标跟踪方法与目前主流的多目标跟踪(MOT)方法在DanceTrack测试集及“私有检测器”协议(“private detector”protocol)下(MOT挑战赛官方比较方法的一种协议)的MOT17测试集上进行比较,结果分别见表2和表3,其中“↑”表示指标越高越好,最佳结果以粗体显示。所有结果均直接从DanceTrack、MOT挑战赛官方评估服务器获取。

表2 不同方法在DanceTrack测试集上的对比

Table 2 Comparison of different methods on DanceTrack test set  
单位:%

| Type          | Method                      | MOTA ↑      | HOTA ↑      | IDF1 ↑      | FPS ↑       |
|---------------|-----------------------------|-------------|-------------|-------------|-------------|
| 检测联合跟踪        | CenterTrack <sup>[22]</sup> | 86.8        | 41.8        | 35.7        | 17.5        |
|               | TraDes <sup>[23]</sup>      | 86.2        | 43.3        | 41.2        | 17.5        |
| 基于Transformer | GTR <sup>[24]</sup>         | 84.7        | 48.0        | 50.3        | 19.6        |
|               | MOTR <sup>[10]</sup>        | 79.7        | 54.2        | 51.5        | 7.5         |
| 基于KF          | FairMOT <sup>[25]</sup>     | 82.2        | 39.7        | 40.8        | 25.9        |
|               | OC-SORT <sup>[8]</sup>      | 89.6        | 54.6        | 54.6        | 29.0        |
|               | SORT <sup>[14]</sup>        | 91.8        | 47.9        | 50.8        | <b>30.7</b> |
|               | ByteTrack <sup>[12]</sup>   | 89.5        | 47.3        | 52.5        | 29.6        |
|               | B-AKF(Ours)                 | <b>92.2</b> | <b>57.7</b> | <b>58.7</b> | 29.2        |

表3 不同方法在MOT17测试集上的对比

Table 3 Comparison of different methods on MOT17 test set  
单位:%

| Type          | Method                      | MOTA ↑      | HOTA ↑      | IDF1 ↑      | FPS ↑       |
|---------------|-----------------------------|-------------|-------------|-------------|-------------|
| 检测联合跟踪        | CenterTrack <sup>[22]</sup> | 67.8        | 52.2        | 64.7        | 13.2        |
|               | TraDes <sup>[23]</sup>      | 69.1        | 52.7        | 63.9        | 13.2        |
| 基于Transformer | GTR <sup>[24]</sup>         | 75.3        | 59.1        | 71.5        | 14.7        |
|               | MOTR <sup>[10]</sup>        | 73.4        | 57.8        | 68.1        | 5.7         |
| 基于KF          | FairMOT <sup>[25]</sup>     | 73.7        | 59.3        | 72.3        | 19.5        |
|               | OC-SORT <sup>[8]</sup>      | 78.0        | 63.2        | 77.5        | 21.8        |
|               | SORT <sup>[14]</sup>        | 80.1        | 63.0        | <b>78.2</b> | <b>23.1</b> |
|               | ByteTrack <sup>[12]</sup>   | <b>80.3</b> | 63.1        | 77.3        | 22.3        |
|               | B-AKF(Ours)                 | <b>80.3</b> | <b>63.3</b> | 77.3        | 22.0        |

从表2的结果可知,B-AKF在目标具有不规则运动的DanceTrack测试集上,MOTA比次优的SORT高0.4个百分点,HOTA比次优的OC-SORT高3.1个百分点,IDF1比次优的OC-SORT高4.1个百分点。出现上述现象的可能原因是:B-AKF中提出的AKF具有较强的适应能力从而能提高对不规则运动目标的跟踪准确度,加上所提出的BiIoUG算法具有较为出色的数据关联能力,从而取得了较高的MOTA、HOTA和IDF1,说明B-AKF针对运动不规则目标跟踪的改进是有效的。

从表3的结果可知,B-AKF在目标具有规律运动的MOT17测试集上,MOTA比次优的SORT高0.2个百分点,HOTA比次优的OC-SORT高0.1个百分点,IDF1比最优的SORT低0.9个百分点。导致以上结果的可能原因是:在MOT17数据集光照强度较低场景下,B-AKF的

身份保持能力有所下降,因此IDF1稍低于SORT,但在MOTA、HOTA指标上都取得了最高的分数,说明B-AKF对运动较为规律目标的跟踪也有较好的表现。

从表2和表3可以看出,在DanceTrack测试集和MOT17测试集上,基于卡尔曼滤波KF的多目标跟踪方法(FairMOT、OC-SORT、SORT、ByteTrack、B-AKF)与基于Transformer范式的多目标跟踪方法(GTR、MOTR)、检测联合跟踪范式的多目标跟踪方法(CenterTrack、TraDes)相比,获得的FPS更高,其中,B-AKF的FPS超越了表中大部分主流多目标跟踪方法。以上结果说明基于KF的多目标跟踪方法在计算时间复杂度上优于基于Transformer范式和检测联合跟踪范式的多目标跟踪方法。此外,在基于KF的多目标跟踪方法中,虽然本文所提出的B-AKF在FPS上比最优的SORT稍低,但前者比后者跟踪准确度更高,B-AKF以少量效率的损失换取跟踪准确度的提升,更适合对跟踪准确度要求高的应用场合。导致以上结果的可能原因在于:采用TBD范式的方法中的耗时主要分布在检测部分,跟踪部分耗时占比较低,在某些情况下与检测部分相比甚至可以忽略不计,也就是说方法整体的耗时主要由检测部分决定。本文提出的方法采用的是TBD范式,先使用YOLOx进行检测再使用运动模型AKF进行跟踪,方法的耗时主要分布在检测部分,跟踪部分AKF耗时占比较低,且由于检测部分采用的是实时性相对较好的YOLOx,因此方法的整体耗时相对较少,时效性较好。表2、表3中FPS相关实验的结果也证实了这一结论,这也与同类方法(采用TBD范式的方法)文献(如参考文献[12])得出的结论一致。

3.6 跟踪效果可视化

为了更直观地展示所提出方法对运动不规则目标的跟踪效果,选择同类多目标跟踪方法在DanceTrack中的视频序列上进行目标跟踪并加以可视化展示,如图4所示。图中,分别采用SORT、ByteTrack和本文提出的B-AKF对视频序列的第430、435和440帧中的目标进行跟踪,同一个目标用相同颜色的方框及相同的ID表示,需要重点关注的目标以“▲”标注出。




图4 部分视频序列跟踪可视化

Fig.4 Visualization of partial video sequence tracking

从图4的跟踪结果可看出:(1)在第435帧中各方法均存在ID短暂消失现象,如SORT在435帧中除了被完



全遮挡的目标(ID“2”)外,对于部分被遮挡的目标(ID“3”)未能跟踪导致ID短暂消失;ByteTrack对于未被遮挡的目标(ID“1”)和被完全遮挡的目标(ID“2”)未能跟踪导致ID短暂消失;而所提出方法B-AKF能准确跟踪3个目标。直到第440帧各方法才恢复对所有目标的跟踪。出现上述现象可能的原因是由于视频中目标的不规律运动,使得ByteTrack、SORT身份保持能力较差,而B-AKF有BIOUG算法能加强身份保持能力,因此跟踪表现相对较好。(2)部分方法存在ID改变现象,如SORT和ByteTrack中重点关注目标的ID在440帧时发生了改变,即同一个目标,在430帧时ID是“2”,到了440帧时ID变成了“5”,而B-AKF未发生ID改变。出现以上结果的可能原因是由于视频中目标的不规律运动,再加上目标(ID“2”)在435帧时被另一个目标(ID“1”)遮挡的条件下,SORT及ByteTrack难以预测该目标的运行轨迹,体现在跟踪结果上两者都跟丢了目标(ID“2”),而B-AKF可以根据AKF动态预测目标运动情况,因此能较准确地进行跟踪。通过跟踪效果可视化实验可以看出,所提出的B-AKF对运动不规律目标的跟踪有较好的表现。

### 3.7 消融实验

在DanceTrack的验证集上进行消融实验,以探究所提出的AKF及BIOUG算法对于B-AKF的影响,并分析其可能的原因。在消融实验中,为测试所提出自适应卡尔曼滤波AKF的影响,在B-AKF中仅将其替换为常规卡尔曼滤波,此时的方法记为B-AKF(-AKF);为测试BIOUG贪婪算法的影响,在B-AKF中仅将该算法替换为默认的匈牙利算法,此时方法记为B-AKF(-BIOUG);不使用AKF和BIOUG的方法记为Baseline;两者都使用时的方法记为B-AKF。消融实验对比结果如表4所示,其中“√”和“×”分别表示实验中包含和未包含对应模块,“↑”表示指标越高越好,表格中最佳结果以粗体显示。主要结论概括如下。

(1)AKF的影响:B-AKF与不使用AKF的B-AKF(-AKF)相比,MOTA、IDF1、HOTA分别提升了1.9个百分点、3.3个百分点、7.6个百分点,HOTA提升的幅度最大,说明提出的AKF能较好处理因视频序列中存在目标运动不规律导致跟踪效果较差的问题。实验表明,自适应卡尔曼滤波AKF有利于提高检测、关联和定位性能(HOTA),间接提高了多目标跟踪准确度(MOTA)。

(2)BIOUG算法的影响:B-AKF与不使用BIOUG算

法的B-AKF(-BIOUG)相比,MOTA得分相同,IDF1、HOTA分别提升1.3个百分点、0.6个百分点。导致MOTA未发生改变的可能原因是BIOUG更侧重身份保持和关联能力,对反映跟踪准确度指标MOTA提升不明显;而在反映身份保持的指标IDF1及反映检测、关联和定位共同效果的指标HOTA上都有提升,原因可能是BIOUG更侧重于加强身份保持和关联能力,有利于减少身份切换,降低了误匹配的概率,进而增强匹配的准确率。

(3)除Baseline外的其他方法与Baseline相比指标均有提升,说明单独使用AKF与BIOUG算法都对B-AKF方法跟踪性能的提高有所贡献,特别是两者同时使用时跟踪性能比仅使用其一更好,验证了所提出的AKF和BIOUG算法的有效性及其之间的相容性。

### 3.8 方法收敛性分析

对所提出的跟踪方法的收敛速度和收敛精度进行分析。借鉴文献[8]的做法同时为了便于观察,从DanceTrack验证集中随机抽取一段视频并在该视频中随机选择一个目标的前100帧,使用同类多目标跟踪方法SORT和本文提出的跟踪方法对指定目标进行跟踪并观察其收敛过程,如图5所示。其中,目标的真实运动轨迹(ground truth, GT)用绿色线条表示,SORT跟踪的轨迹用蓝色线条表示,本文提出的跟踪方法跟踪的轨迹用红色线条表示,目标的初始位置位于图的最下方。此外,SORT和本文提出的跟踪方法的跟踪轨迹与真实轨迹在每一帧上的跟踪距离误差曲线(tracking distance error, TDE)如图6所示,其中,SORT的跟踪距离误差曲线用




图5 目标运动轨迹及相应跟踪轨迹

Fig.5 Trajectory of object and corresponding tracking trajectories




图6 跟踪距离误差曲线

Fig.6 Tracking distance error curve

表4 消融实验的结果

Table 4 Results of ablation experiments 单位:%

| Method        | AKF | BIOUG | MOTA ↑      | IDF1 ↑      | HOTA ↑      |
|---------------|-----|-------|-------------|-------------|-------------|
| Baseline      | ×   | ×     | 88.1        | 51.1        | 47.0        |
| B-AKF(-AKF)   | ×   | √     | 88.3        | 52.3        | 47.2        |
| B-AKF(-BIOUG) | √   | ×     | <b>90.2</b> | 54.3        | 54.2        |
| B-AKF         | √   | √     | <b>90.2</b> | <b>55.6</b> | <b>54.8</b> |

蓝色线条表示,本文提出的跟踪方法的跟踪距离误差曲线用红色线条表示。

从图5可以看出,本文提出的跟踪方法得到的跟踪轨迹比SORT更快地逼近GT,并且之后的轨迹也与GT拟合度更高。从图6可以看出,SORT在第13帧左右跟踪距离误差曲线趋于收敛,而本文提出的方法在第8帧左右已经趋于收敛,可见本文提出的方法收敛速度更快;在第13帧(两种方法都已收敛)之后本文提出的方法相较于SORT跟踪距离误差更小,可见本文提出的方法的收敛精度更高。产生上述现象的可能原因是:本文方法采用了所提出的自适应卡尔曼滤波AKF,可以根据目标的运动状态以及目标检测器的输出结果及时更新运动噪声协方差矩阵以及观测噪声协方差矩阵,使其反映不规则运动目标当前的准确位置,从而能够较为准确地预测出目标的运动轨迹,提高方法的收敛速度和收敛精度。

#### 4 结束语

本文提出的自适应卡尔曼滤波AKF根据跟踪目标的运动情况自适应调整噪声协方差矩阵,以解决运动不规则目标的运动轨迹预测不精确的问题;提出的BiOUG贪婪算法通过扩大轨迹匹配空间来优化轨迹匹配过程,以解决轨迹误匹配的问题。在此基础上,提出一种采用二次匹配策略的多目标跟踪方法B-AKF,以解决对运动不规则多目标的跟踪问题。在目标运动不规则的MOT数据集(DanceTrack)上的实验结果表明,所提出方法的MOTA、HOTA、IDF1分别达到了92.2%、57.7%、58.7%,均超越了目前主流的多目标跟踪方法;此外,在目标运动较为规律的MOT数据集(MOT17)上的实验中,所提出方法也体现出较好的性能。实验结果表明所提出的多目标跟踪方法B-AKF具有良好的综合表现,对于不规则运动及规律运动的目标都可以进行有效跟踪,为复杂跟踪任务提供了有效解决方案。在未来的研究中,针对诸如光照强度变化等复杂实际应用场景,利用深度学习等方法提取目标特征信息并将其用于辅助目标跟踪,以进一步提升方法的鲁棒性和适用性。

#### 参考文献:

- [1] 汪强, 卢先领. 时空模板更新的Transformer目标跟踪算法[J]. 计算机科学与探索, 2023, 17(9): 2161-2173.  
WANG Q, LU X L. Transformer object tracking algorithm based on spatio-temporal template update[J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(9): 2161-2173.
- [2] 姜文涛, 张博强. 通道和异常适应性的目标跟踪算法[J]. 计算机科学与探索, 2023, 17(7): 1644-1657.  
JIANG W T, ZHANG B Q. Object tracking algorithm with

- channel and anomaly adaptation[J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(7): 1644-1657.
- [3] 卢锦, 马令坤, 吕春玲, 等. 基于代价参考粒子滤波器组的多目标检测前跟踪算法[J]. 自动化学报, 2024, 50(4): 851-861.  
LU J, MA L K, LYU C L, et al. A multi-target track-before-detect algorithm Based on cost-reference particle filter bank [J]. Acta Automatica Sinica, 2024, 50(4): 851-861.
- [4] 王雒, 李颢, 傅瑞罡. 基于改进ByteTrack算法的红外地面多目标跟踪方法[J]. 计算机科学, 2023, 50(9): 176-183.  
WANG L, LI B, FU R G. Infrared ground multi-object tracking method based on improved ByteTrack algorithm[J]. Journal of Computer Science, 2023, 50(9): 176-183.
- [5] 曹玉东, 陈冬昊, 曹睿, 等. 融合Mask R-CNN的在线多目标行人跟踪方法[J]. 计算机工程与科学, 2023, 45(7): 1216-1225.  
CAO Y D, CHEN D H, CAO R, et al. An online multi-pedestrian tracking method with Mask R-CNN[J]. Computer Engineering and Science, 2023, 45(7): 1216-1225.
- [6] DU Y, ZHAO Z, SONG Y, et al. StrongSORT: make deepsort great again[J]. IEEE Transactions on Multimedia, 2023, 25: 8725-8737.
- [7] SUN P, CAO J, JIANG Y, et al. Dancetrack: multi-object tracking in uniform appearance and diverse motion[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 20993-21002.
- [8] CAO J, PANG J, WENG X, et al. Observation-centric SORT: rethinking sort for robust multi-object tracking[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023: 9686-9696.
- [9] YANG F, ODASHIMA S, MASUI S, et al. Hard to track objects with irregular motions and similar appearances? make it easier by buffering the matching space[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 2023: 4799-4808.
- [10] ZENG F, DONG B, ZHANG Y, et al. MOTR: end-to-end multiple-object tracking with transformer[C]//Proceedings of the European Conference on Computer Vision, 2022: 659-675.
- [11] DU Y, WAN J, ZHAO Y, et al. GIAOTracker: a comprehensive framework for MCMOT with global information and optimizing strategies in VisDrone 2021[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 2809-2819.
- [12] ZHANG Y, SUN P, JIANG Y, et al. Bytetrack: multi-object tracking by associating every detection box[C]//Proceedings of the European Conference on Computer Vision, 2022: 1-21.
- [13] WOJKE N, BEWLEY A, PAULUS D. Simple online and realtime tracking with a deep association metric[C]//Proceedings of the 2017 IEEE International Conference on

- Image Processing, 2017: 3645-3649.
- [14] BEWLEY A, GE Z, OTT L, et al. Simple online and real-time tracking[C]//Proceedings of the 2016 IEEE International Conference on Image Processing, 2016: 3464-3468.
- [15] BOCHINSKI E, EISELEIN V, SIKORA T. High-speed tracking-by-detection without using image information[C]//Proceedings of the 14th IEEE International Conference on Advanced Video and Signal Based Surveillance, 2017: 1-6.
- [16] GE Z, LIU S, WANG F, et al. YOLOx: exceeding YOLO series in 2021[J]. arXiv:2107.08430, 2021.
- [17] 孙凌云, 刘文瀚, 李庆翔, 等. 自适应容积卡尔曼滤波激光视觉融合定位研究[J]. 应用激光, 2024, 44(2): 104-112.
- SUN L Y, LIU W H, LI Q X, et al. Adaptive volumetric Kalman filtered laser vision fusion localization study[J]. Applied Laser, 2024, 44(2): 104-112.
- [18] AKHLAGHI S, ZHOU N, HUANG Z. Adaptive adjustment of noise covariance in Kalman filter for dynamic state estimation[C]//Proceedings of the 2017 IEEE Power & Energy Society General Meeting, 2017: 1-5.
- [19] 孙铭芳, 吕旭, 赵仁杰, 等. 基于新息自适应的扩展卡尔曼滤波雷达目标跟踪算法[J]. 科学技术与工程, 2023, 23(9): 3738-3743.
- SUN M F, LYU X, ZHAO R J, et al. An adaptive extended Kalman filter algorithm based on innovation sequence for radar target tracking[J]. Science Technology and Engineering, 2023, 23(9): 3738-3743.
- [20] MILAN A, LEAL- TAIXÉ L, REID I, et al. MOT16: a benchmark for multi-object tracking[J]. arXiv:1603.00831, 2016.
- [21] CHAABANE M, ZHANG P, BEVERIDGE J R, et al. Deft: detection embeddings for tracking[J]. arXiv:2102.02267, 2021.
- [22] ZHOU X, KOLTUN V, KRÄHENBÜHL P. Tracking objects as points[C]//Proceedings of the 16th European Conference on Computer Vision, 2020: 474-490.
- [23] WU J, CAO J, SONG L, et al. Track to detect and segment: an online multi-object tracker[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 12352-12361.
- [24] ZHOU X, YIN T, KOLTUN V, et al. Global tracking transformers[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 8771-8780.
- [25] ZHANG Y, WANG C, WANG X, et al. FairMOT: on the fairness of detection and re-identification in multiple object tracking[J]. International Journal of Computer Vision, 2021, 129: 3069-3087.